

Atlas de figuras

Análise exploratória da base, das partições e dos resultados do HDBSCAN

Heitor Rodrigues Sabino

Setembro de 2026

Sobre este documento

Reúne as treze figuras produzidas pelos scripts em `src/analysis/`, explicando o que cada uma mostra, como lê-la e o que ela significa para o trabalho. As figuras são geradas por código versionado, não montadas à mão:

```
python src/analysis/dataset_analysis.py    # results/figures/dataset
python src/analysis/fold_analysis.py       # results/figures/folds
python src/analysis/hdbscan_metrics.py     # results/figures/hdbscan
```

Uma decisão que atravessa todas as figuras. O poder discriminante é medido por **AUPRC** (precisão média), nunca por AUC ROC. Com 0,172% de fraudes, o AUC ROC é dominado pela ordenação dos 284.315 negativos — que não é a pergunta — e reporta valores bem mais generosos do que os dados sustentam. O AUPRC mede a precisão no topo do ranking, que é o que importa quando apenas uma fração mínima das transações será acusada.

Onde aparece o termo *lift*, trata-se do AUPRC dividido pela prevalência, isto é, pelo AUPRC de 0,001727 que um ordenador aleatório obteria. Lift igual a 1 significa nenhuma informação.

Parte I — A base de dados

1 Matriz de correlação




Figura 1: Correlação de Pearson entre as 31 variáveis. As linhas escuras destacam **Time**, **Amount** e **Class**, as únicas que não resultam do PCA.

Como ler. Azul indica correlação negativa, vermelho indica positiva, cinza indica ausência de correlação. A diagonal é sempre 1 por construção.

O que mostra. O bloco central é inteiramente neutro: as componentes V1–V28 não se correlacionam entre si. A correlação absoluta máxima entre elas é de $2,32 \times 10^{-14}$, ou seja, zero numérico.

O que significa. A ortogonalidade é esperada, já que as componentes principais são construídas justamente para serem não correlacionadas. A consequência prática é que **nenhum tratamento de multicolinearidade é necessário** — decisão que a Metodologia registra e que esta figura fundamenta. As únicas faixas com estrutura visível são as de **Time**, **Amount** e **Class**, que ficaram fora da transformação.

2 Poder discriminante de cada variável




Figura 2: Lift do AUPRC de cada variável aplicada isoladamente, em escala logarítmica. Em laranja, as duas variáveis originais.

Como ler. Cada barra mede quantas vezes a variável, sozinha, ordena fraudes melhor que o acaso. A escala é logarítmica porque os valores variam três ordens de grandeza. A linha em 1 marca o ordenador aleatório.

O que mostra. V14 lidera com lift de 357× (AUPRC 0,617), seguida de V17 (356×) e V12 (336×). No extremo oposto, Time obtém apenas 1,43× e Amount, 2,45×.

O que significa. A escolha da métrica não é detalhe de forma. Medido por AUC ROC, V17 aparecia em oitavo lugar e V4 em segundo; por AUPRC, V17 sobe para o segundo e V4 cai para o décimo. A razão é que V4 ordena bem os negativos — o que o AUC ROC premia — mas não coloca as fraudes no topo do ranking. V17, por sua vez, é a variável de maior correlação absoluta com a classe (−0,327), e o AUC ROC a escondeia.

3 A variável Time é relevante?




Figura 3: Distribuição temporal das duas classes ao longo das 48 horas de coleta (a), perfil por hora do dia (b) e taxa de fraude por faixa horária (c).

Como ler. Em (a) e (b) as curvas são normalizadas *dentro de cada classe*: sem isso, as 492 fraudes seriam invisíveis ao lado das 284.315 transações legítimas. O painel (c) muda de perspectiva e mostra, para cada faixa de três horas, quantas fraudes ocorrem a cada 10.000 transações.

O que mostra. A resposta tem duas partes, e elas parecem contraditórias até que se observe o que cada painel mede.

Como ordenador isolado, **Time** é quase inútil: AUPRC de 0,0025, lift de $1,43\times$, 271 posição entre 30 variáveis, correlação de $-0,012$ com a classe.

Mas o painel (c) revela estrutura real. A faixa das 03h às 06h concentra **58,7 fraudes por 10.000 transações**; a das 21h às 24h, apenas **10,4**. Uma razão de 5,6 vezes.

O que significa. As duas leituras convivem porque medem coisas diferentes. A hora do dia *multiplica a probabilidade a priori* de fraude, mas não serve para *ordenar transações uma a uma* — a maioria das fraudes ocorre durante o dia, junto com a maioria das transações. A variável bruta não merece entrar no modelo pelo seu poder isolado; a hora do dia derivada dela é candidata legítima a variável construída.

4 Distribuições por classe




Figura 4: Distribuição das seis variáveis de maior AUPRC, separadas por classe. Valores escalonados pelo mesmo pré-processamento do pipeline.

Como ler. Cada curva é normalizada dentro da própria classe, de modo que a comparação é de *formato*, não de volume.

O que mostra. Em todas as seis variáveis as duas distribuições se deslocam visivelmente uma em relação à outra, e em cinco delas a fraude desloca-se para valores menores — coerente com o sentido registrado na tabela de poder discriminante.

O que significa. A separação existe, mas há sobreposição substancial em todos os casos. Nenhuma variável isolada resolve o problema, o que justifica a abordagem multivariada. Também explica por

que o melhor AUPRC individual é 0,617 e não algo próximo de 1.

5 Projeções bidimensionais




Figura 5: Fraudes projetadas nos pares formados pelas três componentes de maior AUPRC.

Como ler. As transações legítimas aparecem em azul, como amostra de 20.000 pontos; as fraudes, em laranja, *todas as 492*, desenhadas por cima com anel de contorno. A subamostragem é necessária: com 284 mil pontos sobrepostos, as fraudes ficariam soterradas.

O que mostra. As fraudes formam uma nuvem difusa que se estende para fora do bloco denso das transações legítimas, com uma região de sobreposição onde as duas classes convivem.

O que significa. Os eixos foram escolhidos pelo **AUPRC individual, não pela variância**. Isso merece nota: as componentes já resultam de PCA, e a ordem do PCA reflete variância total, que não coincide com poder de separação entre classes. Projetar em V1, V2 e V3 mostraria as direções de maior espalhamento, não as de maior informação sobre fraude.

6 Estrutura tridimensional



Figura 6: A mesma nuvem de pontos vista de quatro ângulos, em $V14 \times V17 \times V12$.

Como ler. Os quatro painéis contêm exatamente os mesmos dados; só a posição do observador muda.

O que mostra. A separação entre as duas nuvens persiste em todos os ângulos. O bloco azul permanece compacto e a nuvem laranja permanece dispersa ao seu redor, independentemente da direção de observação.

O que significa. Um único ângulo pode criar separação aparente por oclusão — pontos que apenas parecem separados porque estão alinhados com a linha de visão. A rotação descarta esse artefato: a estrutura é genuína, não um acidente de projeção.

7 Densidade local: a premissa sob teste




Figura 7: Distribuição da distância ao 20º vizinho mais próximo (a) e curvas de quantis das duas classes (b).

Como ler. A distância ao vigésimo vizinho é uma medida inversa de densidade: quanto maior, mais isolado está o ponto. As linhas verticais em (a) marcam as medianas. A densidade é estimada por núcleo, e não por histograma, porque com apenas 492 fraudes um histograma seria dominado por ruído de discretização.

O que mostra. As duas distribuições mal se sobrepõem. A distância mediana é de 2,59 para transações legítimas e de 7,92 para fraudes — uma razão de **3,06 vezes**. O teste de Kolmogorov-Smirnov acusa $D = 0,793$, com p abaixo do menor valor representável em ponto flutuante.

O que significa. Esta é a figura mais importante do conjunto. Ela é a **evidência empírica direta da premissa do trabalho**: fraudes de fato ocupam regiões de baixa densidade. Sem esse resultado, tratar fraude como ruído seria uma suposição não verificada; com ele, é uma propriedade mensurada da base.

Parte II — As partições da validação cruzada

8 Composição e estratificação




Figura 8: Número absoluto de fraudes por partição (a) e proporção de fraude em cada uma (b), comparada à da base completa.

Como ler. Em (b), a linha horizontal cinza marca a proporção de fraude da base inteira. Qualquer desvio visível indicaria falha na estratificação.

O que mostra. As quatro séries permanecem praticamente coladas à linha de referência. A proporção de fraude varia de 0,1720% a 0,1738% entre todas as partições — amplitude de 0,0018 ponto percentual.

O que significa. A estratificação funcionou. Isso é pré-requisito para comparar os folds entre si: se as partições tivessem proporções diferentes de fraude, qualquer variação de desempenho poderia ser atribuída à composição, e não ao modelo.

9 Cobertura e isolamento




Figura 9: Quantas vezes cada transação foi usada como teste (a) e sobreposição entre os conjuntos de teste dos cinco folds (b).

Como ler. A propriedade desejada é uma única barra em “1” à esquerda, e zeros fora da diagonal à direita.

O que mostra. É exatamente o que se observa. Todas as **284.807** transações foram testadas uma única vez, e a sobreposição entre conjuntos de teste distintos é **nula**.

O que significa. Os conjuntos de teste são mutuamente exclusivos e cobrem a base inteira. A estimativa de desempenho usa cada transação exatamente uma vez, sem reaproveitamento — que é a garantia que a validação cruzada aninhada deve oferecer.

10 Densidade das fraudes por fold




Figura 10: Distribuição da densidade local por classe em cada fold (a) e razão entre as medianas das duas classes (b).

Como ler. Em (a), cada par de caixas compara as duas classes dentro de um mesmo fold. Em (b), a razão acima de 1 indica fraudes em regiões menos densas.

O que mostra. A razão é **notavelmente estável**: $2,93\times$, $2,93\times$, $2,98\times$, $3,02\times$ e $3,03\times$. Amplitude total de 0,10.

O que significa. Este resultado é decisivo para interpretar a instabilidade do HDBSCAN, tratada na Parte III. Ele estabelece que **as cinco partições são estruturalmente equivalentes** do ponto de vista da densidade. Qualquer variação grande de resultado entre elas, portanto, não pode ser atribuída a diferenças nos dados.

Parte III — Resultados do HDBSCAN

11 Estabilidade das métricas




Figura 11: Valor de cada métrica para cada combinação de hiperparâmetros, em cada fold interno. Escalas de cor independentes entre métricas.

Como ler. Cada linha é uma combinação de hiperparâmetros; cada coluna, um fold. Uma linha de tom uniforme indica configuração estável; variação de tom dentro da mesma linha indica sensibilidade à partição.

O que mostra. A maior parte do painel é uniforme. A exceção está concentrada nas linhas de `min_cluster_size = 5`, onde a coloração muda bruscamente entre colunas.

O que significa. A substituição da figura anterior, que mostrava apenas AUC ROC e tinha títulos sobrepostos, permite ver o que estava oculto: a instabilidade não afeta o método como um todo, mas uma região específica do espaço de parâmetros.

12 Amplitude do DBCV por configuração




Figura 12: Intervalo entre o menor e o maior DBCV obtido pela mesma configuração ao longo dos cinco folds, ordenado da menos estável para a mais estável.

Como ler. Cada barra horizontal vai do mínimo ao máximo observado. Barra longa significa que os mesmos hiperparâmetros produziram resultados muito diferentes. Os rótulos em destaque marcam as configurações cuja amplitude supera o dobro da mediana.

O que mostra. A amplitude mediana é de apenas 0,065. Mas as **cinco configurações com `min_cluster_size` = 5** chegam a 0,852 — o DBCV varia de 0,107 a 0,959 com os mesmos parâmetros. As outras vinte configurações são estáveis.

O que significa. Combinando com a Parte II, o argumento fecha. As partições são estruturalmente idênticas (razão de densidade entre $2,93\times$ e $3,03\times$), e ainda assim o DBCV oscila de 0,107 a 0,959 sobre elas. A instabilidade, portanto, **é do algoritmo, não dos dados**.

O problema prático é que essa região instável é justamente a que vence a seleção por DBCV.

13 O DBCV prediz o desempenho?




Figura 13: DBCV — calculado sem consultar os rótulos — contra métricas supervisionadas. Cada ponto é uma combinação avaliada em um fold.

Como ler. O eixo horizontal traz o critério de seleção, que não usa rótulos; o vertical, métricas que os utilizam. Correlação positiva indica que o critério aponta na mesma direção do desempenho real.

O que mostra. O ρ de Spearman global é de +0,70 com AUPRC, com p da ordem de 10^{-20} .

Uma ressalva que a figura torna visível. A distribuição do DBCV é **bimodal**: um grupo denso abaixo de 0,2 e um grupo destacado acima de 0,95, sem nenhuma observação entre os dois. Um coeficiente único calculado sobre os dois grupos mede sobretudo a distância entre eles, e não uma ordenação gradual.

Por isso cada painel reporta também o coeficiente calculado *apenas dentro do regime inferior*: $\rho = +0,66$ com AUPRC, $p \approx 10^{-16}$.

O que significa. A relação se sustenta nas duas leituras. O DBCV distingue corretamente os dois regimes e ordena configurações dentro do regime dominante. Isso justifica seu uso como critério de seleção sem vazamento de rótulos — e a ressalva sobre a bimodalidade precisa acompanhar o número sempre que ele for reportado.

Síntese

Pergunta	Resposta
As componentes do PCA exigem tratamento de multicolinearidade?	Não. Correlação absoluta máxima de $2,32 \times 10^{-14}$ entre elas.
A variável Time é relevante?	Como ordenador, não: lift de $1,43\times$, 27l de 30. Como fator de risco a priori, sim: $5,6\times$ mais fraude entre 03h e 06h.
Fraudes ocupam regiões de baixa densidade?	Sim. Distância mediana ao 20º vizinho $3,06\times$ maior ($D = 0,793$).
A estratificação se manteve?	Sim. Proporção de fraude entre 0,1720% e 0,1738%.
Cada transação é testada uma única vez?	Sim. 284.807 transações, sobreposição nula entre conjuntos de teste.
O HDBSCAN é instável?	Apenas em <code>min_cluster_size = 5</code> . Amplitude mediana de 0,065; nessa região, 0,852.
A instabilidade vem dos dados ou do algoritmo?	Do algoritmo. A razão de densidade das partições varia só de $2,93\times$ a $3,03\times$.
O DBCV é um critério de seleção defensável?	Sim, com ressalva. $\rho = +0,70$ global e $+0,66$ dentro do regime inferior, mas a distribuição é bimodal.