

Detecção de fraudes financeiras

Agrupamento HDBSCAN em comparação com Random Forest e XGBoost

Heitor Rodrigues Sabino

Universidade Federal de Lavras

Orientadora: Elaine Cecilia Gatto

Coorientador: Natanael Fabrício Dacioli Batista

2026

O problema

Fraude em cartão de crédito é um evento **raro** e **mutável**.

- A base do Machine Learning Group da ULB tem 284.807 transações e apenas **492 fraudes** — 0,172%.
- Modelos supervisionados aprendem os padrões de fraude **já rotulados**. Fraudes novas, por definição, não estão nos rótulos.
- Rotular transações é caro e sempre chega atrasado.

Hipótese

Se fraude é uma anomalia, um algoritmo de densidade deveria encontrá-la **sem usar os rótulos** — como ruído.

Um algoritmo não supervisionado de agrupamento por densidade compete com classificadores supervisionados na detecção de fraudes?

Não supervisionado

- HDBSCAN
- Fraude = ruído (rótulo -1)
- Não vê a coluna *Class* no treino

Supervisionados (referência)

- Random Forest
- XGBoost
- Treinam com os rótulos

Validação cruzada aninhada estratificada

Partição	Treino	Avaliação
5 <i>folds</i> externos (80/20)	227.845	56.961
Divisão interna (80/20)	182.276	45.569

- Estratificada: cada partição preserva os 0,172% de fraude.
- Os dados que escolhem hiperparâmetros **nunca** são os que estimam o desempenho.

Pré-processamento

- Time: padronização Z-score — variável incremental e limitada.
- Amount: *Robust Scaler* — os valores vão de 0,00 a 25.691,16, com mediana de 22,00.
- V1–V28: mantidas; já são componentes de PCA.

Busca em grade no ciclo interno

- Supervisionados: seleção por **F1**.
- HDBSCAN: seleção por **DBCV** (*Density-Based Clustering Validation*).

Por que DBCV

É uma métrica interna: avalia a qualidade do agrupamento sem consultar os rótulos. Usar F1 aqui contaminaria a etapa não supervisionada.

O HDBSCAN é **instável** entre **partições quase idênticas**.

Mesma configuração (`min_cluster_size=5`, `min_samples=300`), cinco *folds* internos:

	mínimo	máximo	amplitude
DBCV	0,107	0,959	0,852
Pontos de ruído	7.985	130.231	122.246

- Como fraude é o rótulo de ruído, essa amplitude determina diretamente quantas transações o modelo acusa.
- O F1 do HDBSCAN ficou entre **0,011 e 0,070**.

Critério de seleção: máximo ou média?

O ciclo interno elege o maior DBCV entre os cinco *folds*. Numa distribuição tão instável, o máximo seleciona também o *fold* mais favorável. A média é a escolha usual da validação aninhada.